```
class fasta data:
       self.f = open(file name).read()
       self.records = {}
            if line.startswith(">"):
                   self.records[self.id] = self.seq
                self.id = line.split(" ")[0][1:]
               self.seq = ""
           else:
                self.seq += line.strip()
   def get records(self):
       return self.records
       return self.records.keys()
   def get seg(self):
       return self.records.values()
   def reads number(self):
       return len(self.records)
   def get lengths(self):
       length = {}
       for id, seq in self.records.items():
           length[id] = len(seq)
       min length = min(length.values())
       max length = max(length.values())
       min ids = [id for id, seq len in length.items() if seq len == min length]
       max ids = [id for id, seq len in length.items() if seq len == max length]
       return length, min length, max length, min ids, max ids
       start codon = 'ATG'
       stop codons = ['TAA', 'TAG', 'TGA']
       orfs = {}
       for id, sequence in self.records.items():
           frame seq = sequence[frame-1:]
           for i in range(0, len(frame seq), 3):
                if frame seq[i:i+3] == start codon:
```

```
for j in range(i+3, len(frame_seq), 3):
                        if frame_seq[j:j+3] in stop_codons:
                            orfs[id].append((i+1, j+3, frame seq[i:j+3]))
        longest orf = max((tuple(list(orf) + [id]) for id, orfs list in orfs.items() for
orf in orfs list), key=lambda x: x[1] - x[0])
        return orfs, longest orf
    def repeats(self, n):
        repeats = {}
        for sequence in self.records.values():
            for i in range(len(sequence) - n + 1):
                if sequence[i:i+n] in repeats:
                    repeats[sequence[i:i+n]] += 1
                else:
                    repeats[sequence[i:i+n]] = 1
        most common = max(repeats.items(), key=lambda x: x[1])
        return repeats, most common
reads = fasta data("dna.example.fasta")
records = reads.get records()
reads number = reads.reads number()
records lengths = reads.get lengths()
print("minimum length: " + str(records lengths[1]))
print("maximum length: " + str(records lengths[2]))
print("minimum ids: " + str(records lengths[3]))
print("maximum ids: " + str(records lengths[4]))
orfs1, longest orf1 = reads.reading frames(1)
orfs2, longest orf2 = reads.reading frames(2)
orfs3, longest orf3 = reads.reading frames(3)
print("longest ORF in frame 1: " + str(longest_orf1[:2]))
print("longest ORF in frame 2: " + str(longest orf2[:2]))
print("longest ORF in frame 3: " + str(longest orf3[:2]))
print("longest ORF in frame 1 id: " + str(longest orf1[-1]))
   repeat, most common = reads.repeats(i)
final reads = fasta data("dna2.fasta")
```

```
orfs1, longest orf1 = final reads.reading frames(1)
print("longest ORF in frame 1: " + str(longest_orf1[1]-longest_orf1[0] + 1))
orfs2, longest_orf2 = final_reads.reading_frames(2)
print("longest ORF in frame 2: " + str(longest orf2[1]-longest orf2[0] + 1))
orfs3, longest orf3 = final reads.reading frames(3)
print("longest ORF in frame 3: " + str(longest orf3[:2]))
print("longest ORF in frame 3: " + str(longest orf3[1]-longest orf3[0] + 1))
lengths = []
lengths.append(max( (repeats[1]-repeats[0] + 1 for repeats in
orfs1["gi|142022655|gb|EQ086233.1|16"])))
lengths.append(max( (repeats[1]-repeats[0] + 1 for repeats in
orfs2["qi|142022655|qb|EQ086233.1|16"])))
lengths.append(max( (repeats[1]-repeats[0] + 1 for repeats in
orfs3["gi|142022655|gb|EQ086233.1|16"])))
print("longest ORF in frame 4: " + str(longest orf4[:2]))
print(lengths )
repeat, most common = final reads.repeats(12)
seqs = []
for seq, reap in repeat.items():
    if reap == most common[1]:
        seqs.append(seq)
print(seqs)
print(len(seqs))
repeat, most common = final reads.repeats(7)
orint(most common)
```

Resultado de ejecución con archivos suministrados:

```
"number of records: 24
minimum length: 512
maximum length: 4805
minimum ids: ['gi/142022655/gb/EQ086233.1/521']
maximum ids: ['gi/142022655/gb/E0086233.1/323']
longest ORF in frame 1: (2824, 4509)
longest ORF in frame 2: (64, 1434)
longest ORF in frame 3: (139, 1746)
longest ORF in frame 1 id: gi/142022655/gb/EQ086233.1/323
5 most common: ('GCGCG', 434)
6 most common: ('CGGCGC', 158)
7 most common: ('GCGCGGC', 74)
8 most common: ('GCGCGGCG', 27)
9 most common: ('CGCGGCGCG', 13)
10 most common: ('GCGCGGCGCG', 8)
11 most common: ('CGCTGCGCGGC', 4)
12 most common: ('CGCGGTCGAGCG', 3)
13 most common: ('GATCGTCGACGAC', 3)
14 most common: ('GTCGCGGTCGAGCG', 2)
15 most common: ('GTCGCGGTCGAGCGG', 2)
16 most common: ('CTTGCTCGCCGCGCCC', 2)
17 most common: ('GCGGCGTCCGGCGCGTC', 2)
18 most common: ('ACCGTGCCGGCCGCCAAC', 2)
19 most common: ('GACCAGCGCGAACGCGCCG', 2)
longest ORF in frame 1: 2394
```

```
longest ORF in frame 2: 1458
longest ORF in frame 3: (1438, 3081)
longest ORF in frame 3: 1644
longest ORF in frame 4: (3070, 4527)
[1509, 1458, 1644]
['CATTCGCCATTC', 'ATTCGCCATTCG', 'TTCGCCATTCGC', 'TCGCCATTCGCC']
4
('CGCGCCG', 59)"
```

1. Clase fasta data

Es una clase que procesa datos de ADN en formato multi-FASTA, con métodos para realizar análisis sobre las secuencias.

a) Inicializador (init)

```
def __init__(self, file_name):
    # Reads the entire file content
    self.f = open(file_name).read()
    self.records = {}
    self.id = ""
    # Processes each line of the file content
    for line in self.f.splitlines():
        # If the line is a header line (starts with ">")
        if line.startswith(">"):
            # If there was a previous sequence, save it to the records
            if self.id != "":
                 self.records[self.id] = self.seq
        # Extracts the identifier from the header line and resets the sequence
            self.id = line.split(" ")[0][1:]
            self.seq = ""
        # If the line is a sequence line, append it to the current sequence
        else:
            self.seq += line.strip()
```

¿Qué hace?

- Abre un archivo FASTA (file name) y lo lee por completo.
- Organiza las secuencias en un diccionario (self.records), donde:
 - o Las claves son los identificadores de las secuencias (líneas que empiezan con >).
 - o Los valores son las secuencias asociadas.

b) Métodos básicos

- get records: Devuelve todas las secuencias en forma de diccionario.
- get id: Devuelve los identificadores de las secuencias.
- get seq: Devuelve las secuencias como una lista de valores.

c) Métodos funcionales

1. Número de registros (reads number)

```
def reads_number(self):
    return len(self.records)
```

Devuelve el número de secuencias en el archivo.

Longitudes de secuencias (get_lengths)

```
def get_lengths(self):
    length = {}
    # Calculate the length for each sequence
    for id, seq in self.records.items():
        length[id] = len(seq)
    # Find the shortest and longest sequences and their identifiers
    min length = min(length.values())
    max_length = max(length.values())
    min_ids = [id for id, seq_len in length.items() if seq_len == min_length]
    max_ids = [id for id, seq_len in length.items() if seq_len == max_length]
    return length, min_length, max_length, min_ids, max_ids
```

¿Qué hace?

- 1. Calcula la longitud de cada secuencia y las guarda en el diccionario length.
- 2. Encuentra:
 - La longitud mínima y máxima de las secuencias.
 - Los identificadores asociados a las secuencias más cortas y más largas.

3. Marcos de lectura abiertos (ORFs) (reading frames)

¿Qué hace?

- 1. Analiza las secuencias para encontrar marcos de lectura abiertos (ORFs):
 - o Empiezan con un codón de inicio (ATG).
 - o Terminan con un codón de parada (TAA, TAG, TGA).
- 2. Identifica los ORFs para un marco de lectura específico (frame).
- 3. Devuelve:
 - Todos los ORFs encontrados.
 - El ORF más largo.

4. Repeticiones (repeats)

¿Qué hace?

- 1. Encuentra todas las subsecuencias de longitud n en las secuencias.
- 2. Cuenta la frecuencia de cada subsecuencia.
- 3. Identifica la subsecuencia más frecuente.

2. Análisis Principal

a) Procesamiento inicial

```
reads = fasta_data("dna.example.fasta")
records = reads.get_records()
print("number of records: " + str(reads number))
```

¿Qué hace?

- Carga el archivo dna.example.fasta.
- Imprime el número total de registros.

b) Longitudes de secuencias

```
records_lengths = reads.get_lengths()
print("minimum length: " + str(records_lengths[1]))
print("maximum length: " + str(records lengths[2]))
print("minimum ids: " + str(records_lengths[3]))
print("maximum ids: " + str(records_lengths[4]))
```

¿Qué hace?

- Calcula y muestra:
 - La longitud mínima y máxima.
 - Los identificadores asociados a las secuencias más cortas y largas.

c) ORFs por marcos de lectura

```
orfs1, longest_orf1 = reads.reading_frames(1)
print("longest_ORF in frame 1: " + str(longest_orf1[:2]))
```

¿Qué hace?

- Identifica los ORFs en el marco 1.
- Imprime el ORF más largo y su posición.

d) Repeticiones comunes

```
for i in range(5,20):
    repeat, most_common = reads.repeats(i)
    print(str(i) + " most common: " + str(most_common))
```

¿Qué hace?

- Busca repeticiones de longitud entre 5 y 20.
- Muestra la repetición más frecuente para cada longitud.

e) Análisis en un segundo archivo

```
final_reads = fasta_data("dna2.fasta")
orfs1, longest orf1 = final reads.reading frames(1)
print("longest ORF in frame 1: " + str(longest orf1[1]-longest orf1[0] + 1))
```

¿Qué hace?

• Realiza los mismos análisis, pero sobre un nuevo archivo (dna2.fasta).

3. Conclusión

Este código:

- Carga y organiza datos de ADN en formato FASTA.
- Realiza análisis básicos como el conteo de secuencias y longitudes.
- Identifica ORFs y repeticiones comunes.
- Ofrece flexibilidad para trabajar con múltiples archivos FASTA.